ML Product Design: ML Canvas

TIM DOSEN MACHINE LEARNING

Introduction

The most useful question to continue working on the AI/ML solution is

"how costly are wrong predictions?"

Answering that question will define the feasibility of the ML project.

Introduction (2)

- Tidak jarang waktu dihabiskan oleh para insinyur dan ilmuwan untuk memecahkan **masalah yang salah** dan membangun model yang tidak digunakan.
- Ketika mereka mengerjakan masalah yang tepat, muncul suatu tantangan **menyelaraskan aktivitas** setiap orang dari latar belakang berbeda (misalnya ilmu data, teknik, produk, bisnis) untuk bisa bekerja sama dalam membangun sesuatu yang inovatif yang menciptakan nilai.
- Salah satu cara untuk mempermudah kolaborasi adalah dengan menggunakan kanvas.

Canvas

- Kanvas sangat populer di komunitas startup, dimulai dengan Lean Canvas yang sangat populer, yang berasal dari ***Business Model Canvas***.
- Kanvas berupa **bagan visual** untuk mendeskripsikan objek kompleks dengan cara yang lebih baik daripada dokumen teks sederhana. Setiap komponen kunci memiliki bloknya sendiri dan blok disusun pada bagan dengan cara yang masuk akal secara visual (berdasarkan kedekatannya).
- Dalam konteks data dan AI (*artificial intelligence*), sebuah kanvas dapat berguna untuk menggambarkan pembelajaran aktual yang terjadi dalam sistem cerdas:
  - Data apa yang kita pelajari?
  - Bagaimana kita menggunakan prediksi yang didukung oleh pembelajaran itu?
  - Bagaimana kita memastikan bahwa semuanya "bekerja" sepanjang waktu?

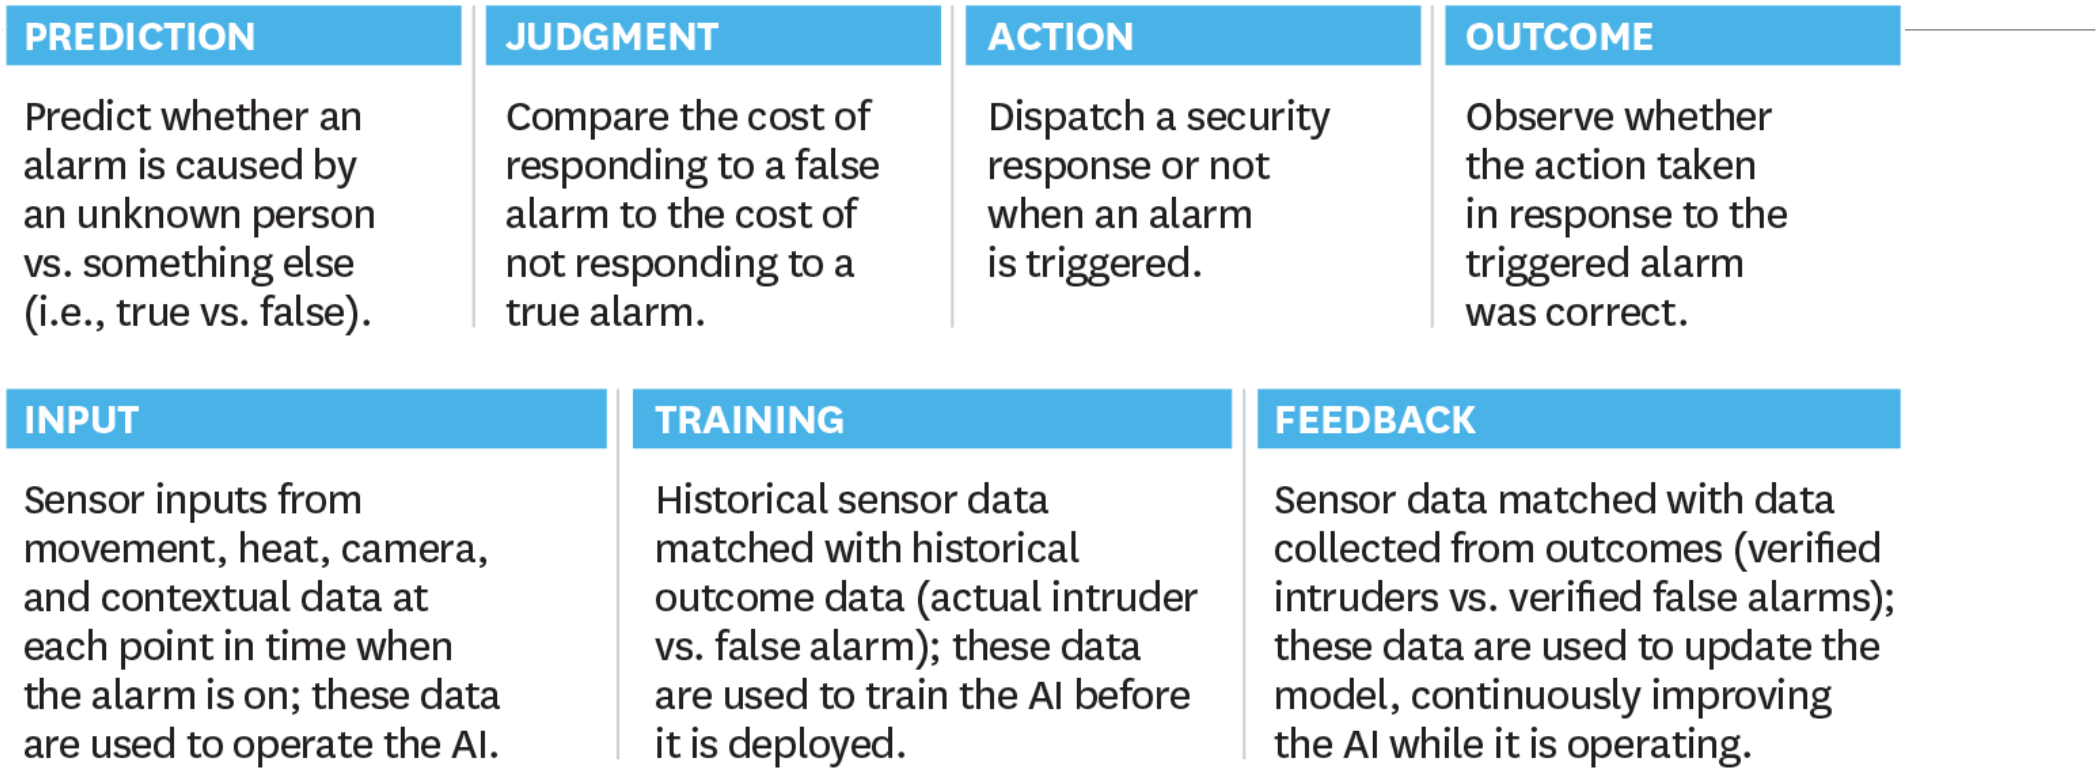
AI Canvas

AI Canvas membantu dalam merancang dan merinci proses prediksi, termasuk mengidentifikasi kebutuhan sistem serta menentukan mekanisme respons terhadap kesalahan yang dihasilkan oleh algoritma prediksi. **AI Canvas** berisi kerangka kerja konseptual untuk merancang dan memetakan penggunaan sistem kecerdasan buatan secara menyeluruh, mulai dari input data, proses prediksi, pengambilan keputusan, tindakan sistem, hingga evaluasi hasil dan umpan balik untuk perbaikan berkelanjutan.

Tujuan utama AI Canvas:

1. Menggambarkan bagaimana AI digunakan dalam suatu sistem atau proses nyata.
2. Menjelaskan hubungan antara data, model, keputusan, dan dampak operasional.
3. Membantu perancangan sistem AI secara end-to-end.

The AI Canvas: An Example Using AI to Improve Home Security



SOURCE AJAY AGRAWAL ET AL.

© HBR.ORG

ML Canvas

Meskipun AI Canvas merepresentasikan struktur tingkat tinggi dari implementasi AI/ML, pada tahap tertentu diperlukan perumusan visi dan spesifikasi sistem machine learning secara lebih rinci. Untuk tujuan tersebut digunakan ML Canvas, seperti yang diperkenalkan oleh Louis Dorard.

ML Canvas membantu menyusun proyek machine learning dan menentukan persyaratan inti yang diperlukan untuk merealisasikannya. Proses ini diawali dengan mengidentifikasi tujuan dengan menjawab pertanyaan “apa yang ingin dicapai bagi end-user dari sistem prediktif?”, kemudian menghubungkan sasaran bisnis dengan tugas machine learning (ML task).

ML Canvas

ML Canvas berisi kerangka kerja untuk merancang dan mengembangkan model machine learning dengan menekankan aspek teknis seperti data, fitur, pelatihan model, evaluasi kinerja, dan implementasi model.

Tujuan utama ML Canvas:

Memetakan proses pembangunan model machine learning.

Mengidentifikasi kebutuhan data dan fitur.

Mengoptimalkan performa model prediksi.

OWNML MACHINE LEARNING CANVAS

Designed for: | Designed by: | Date: | Iteration:

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

THE MACHINE LEARNING CANVAS (V1.0)

Designed for: | Designed by: | Date: | Iteration:

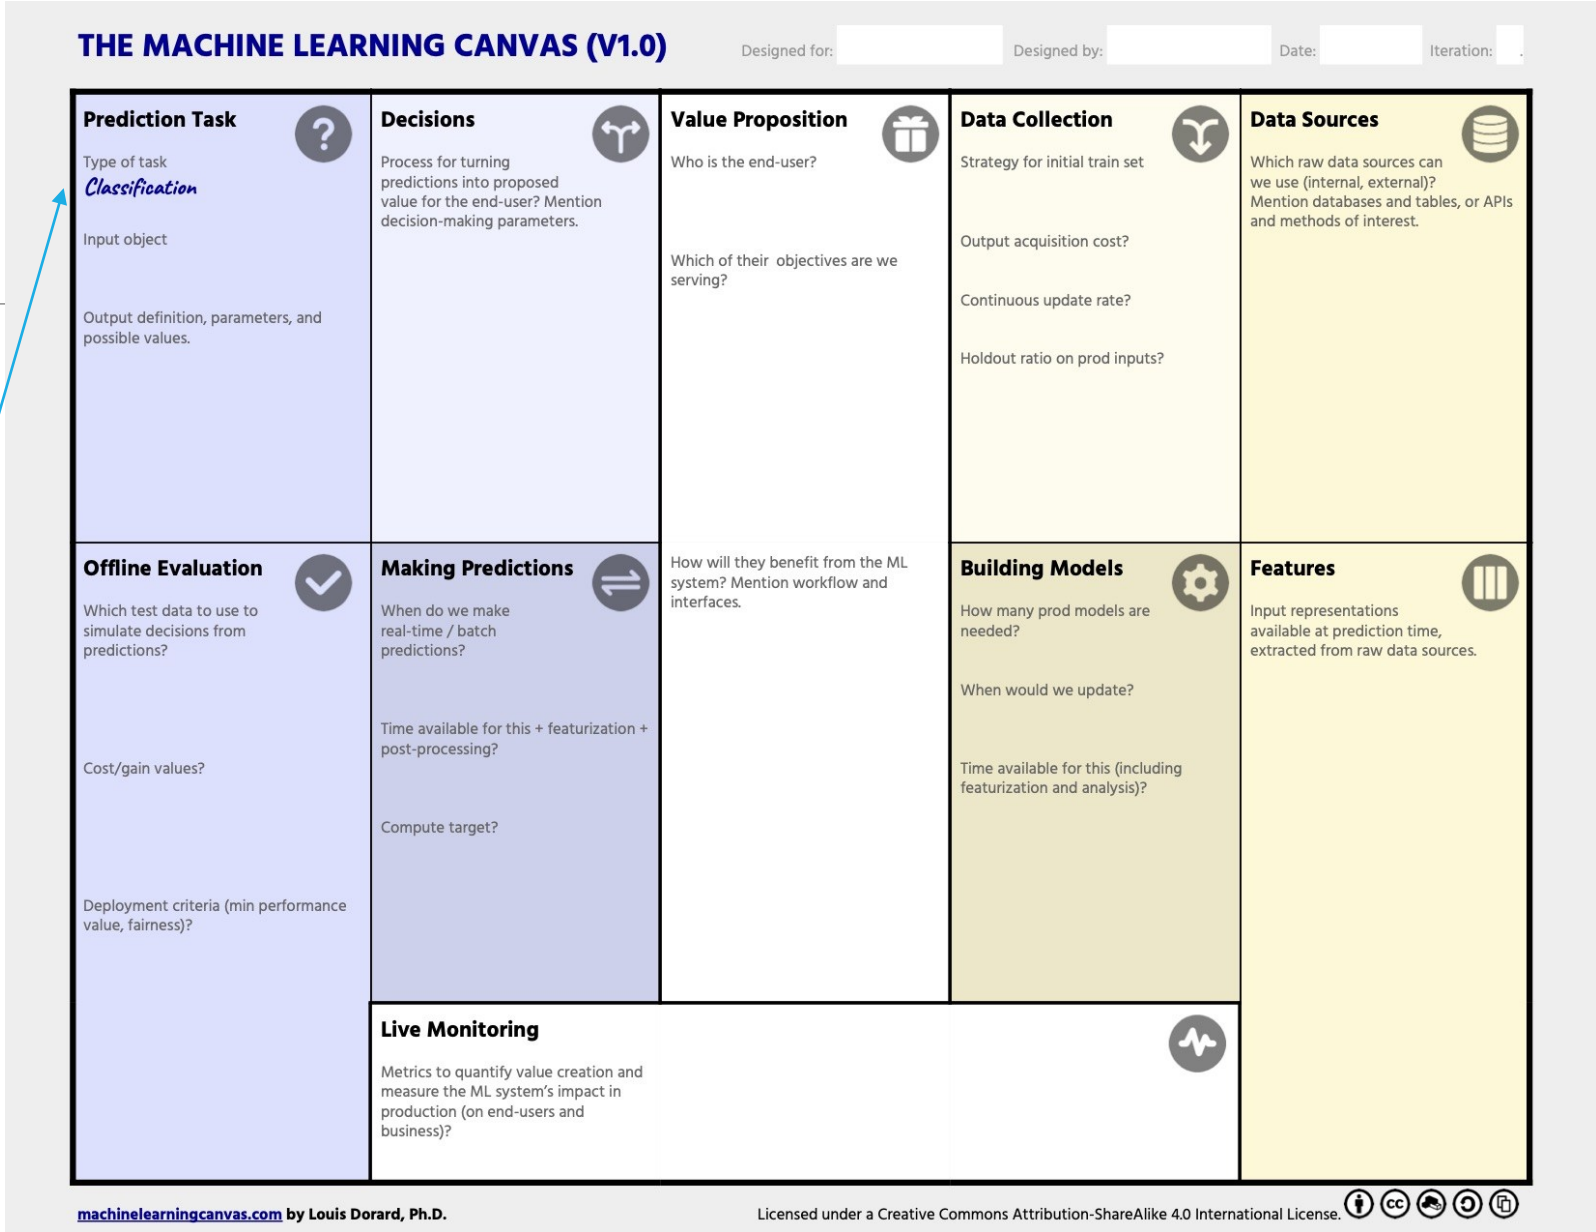
PREDICTION TASK	DECISIONS	VALUE PROPOSITION	DATA COLLECTION	DATA SOURCES
Type of task? Input object? Output: definition, parameters (e.g. prediction horizon), possible values?	Process for turning predictions into proposed value for the end-user? Mention decision-making parameters.	Who is the end-user? What are their objectives? How will they benefit from the ML system? Mention workflow/interfaces.	Strategy for initial train set, and continuous update. Collection rate? Holdout on prod inputs? Output acquisition cost?	Which raw data sources can we use (internal, external)? Mention databases and tables, or APIs and methods of interest.
OFFLINE EVALUATION	**MAKING PREDICTIONS**		**BUILDING MODELS**	**FEATURES**
Simulation of the impact of decisions/predictions? Which test data? Cost/gain values? Deployment criteria (min performance value, fairness)?	When do we make real-time / batch pred.? Time available for this + featurization + post-processing? Compute target?		How many prod models are needed? When would we update? Time available for this (including featurization and analysis)?	Input representations available at prediction time, extracted from raw data sources.
	LIVE MONITORING			
	Metrics to quantify value creation and measure the ML system's impact in production (on end-users and business)?			

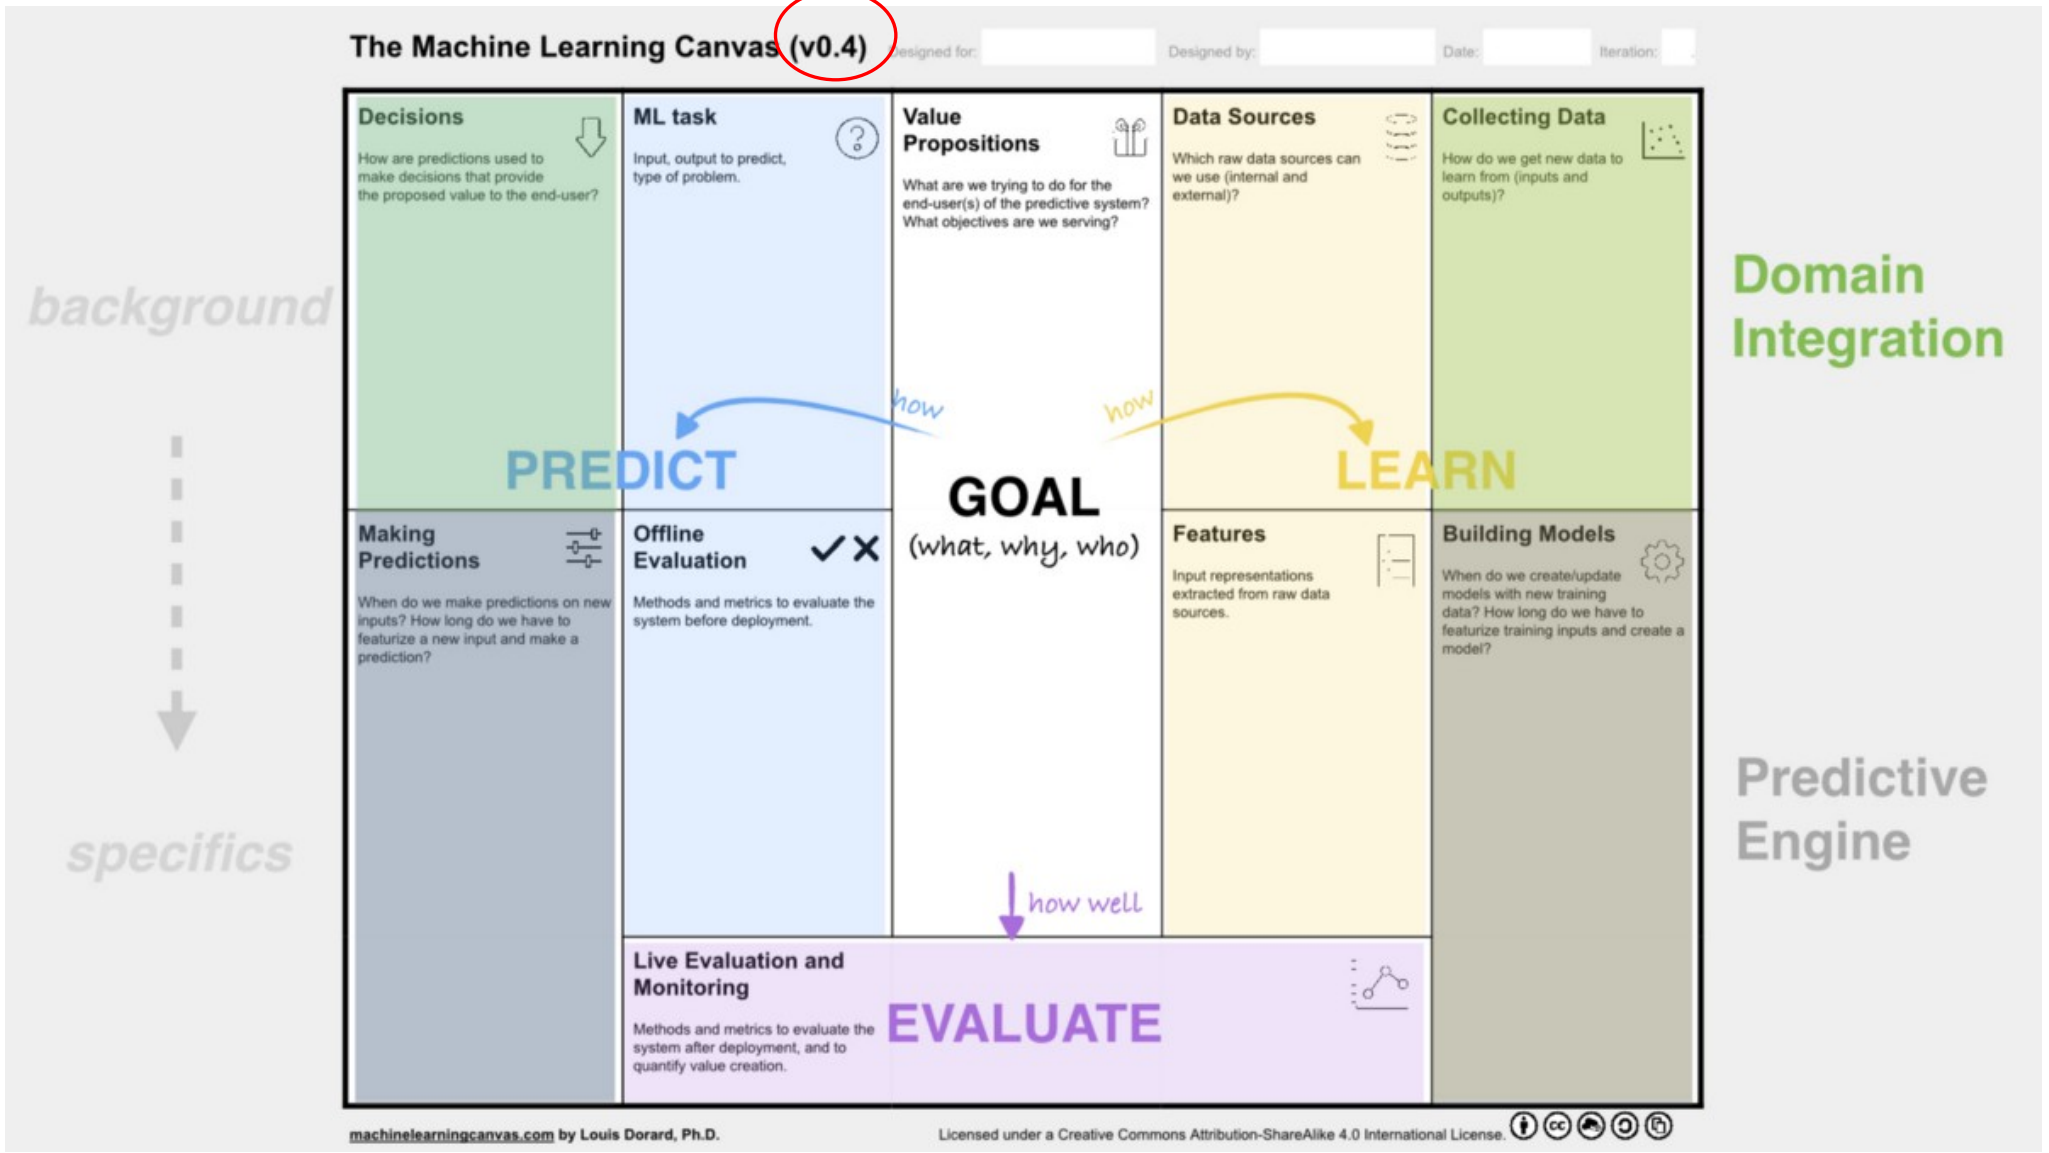
machinelearningcanvas.com by Louis Dorard, Ph.D.

Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.

ML Task yang digunakan adalah **Classification**

Kemudian kita jawab pertanyaan-pertanyaan yang ada di masing-masing blok




The Machine Learning Canvas (v0.4)
Designed for:
Designed by:
Date:
Iteration:
Decisions
How are predictions used to make decisions that provide the proposed value to the end-user?
ML task
Input, output to predict, type of problem.
Value Propositions
What are we trying to do for the end-user(s) of the predictive system? What objectives are we serving?
Data Sources
Which raw data sources can we use (internal and external)?
Collecting Data
How do we get new data to learn from (inputs and outputs)?
background
Domain Integration
how
how
PREDICT
LEARN
GOAL
(what, why, who)
Making Predictions
When do we make predictions on new inputs? How long do we have to featurize a new input and make a prediction?
Offline Evaluation
Methods and metrics to evaluate the system before deployment.
Features
Input representations extracted from raw data sources.
Building Models
When do we create/update models with new training data? How long do we have to featurize training inputs and create a model?
specifics
Predictive Engine
how well
Live Evaluation and Monitoring
Methods and metrics to evaluate the system after deployment, and to quantify value creation.
EVALUATE
machinelearningcanvas.com by Louis Dorard, Ph.D.
Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.

Blocks in ML Canvas

- Bagian tengah kanvas adalah blok bangunan **Value Preposition**, yang menjelaskan produk atau layanan yang menciptakan nilai bagi pelanggan. Biasanya, kita menjawab pertanyaan-pertanyaan berikut:
  - Masalah apa yang coba diselesaikan?
  - Mengapa ini penting?
  - Siapa *end-user* sistem?
  - Nilai apa yang diberikan proyek ML kepada *end-user*?
  - Bagaimana mereka akan menggunakan *outputs/predictions* Anda? (*workflow)*
- Kanvas yang tersisa dibagi menjadi tiga kategori besar:
  - **Learning**, menentukan bagaimana model ML akan dipelajari;
  - **Prediction,** menjelaskan bagaimana prediksi dilakukan; dan
  - **Evaluation,** berisi metode dan metrik untuk model ML dan evaluasi sistem.

Blocks in ML Canvas: Prediction

Bagian di sisi kiri dikhususkan untuk ***Prediction***, berdasarkan model yang akan kita pelajari dari data.

- ML/Prediction Task: Jenis apa (misal: klasifikasi, regresi, dll), apa inputnya, dan apa output yang akan diprediksi (bersama dengan nilai yang mungkin)?
- Decisions: Bagaimana prediksi digunakan untuk membuat keputusan yang memberikan nilai yang diusulkan kepada *end-user*?
- Making Predictions: Kapan kita membuat prediksi tentang input baru dan berapa lama waktu yang kita miliki untuk itu?
- Offline Evaluation: Metode dan metrik mana yang dapat digunakan untuk mengevaluasi cara prediksi yang akan dibuat dan digunakan (*prior to deployment*)?

Blocks in ML Canvas: Learning

Bagian di sisi kanan didedikasikan untuk **Learning** dari data.

- Data Sources: Sumber data mentah mana yang dapat kita gunakan?
- Data Collection: Bagaimana kita mendapatkan data baru untuk dipelajari (input dan output)?
- Features: Representasi input untuk mengekstrak dari sumber data mentah.
- Building Models: Kapan kita membuat/memperbarui model dengan data pelatihan baru dan berapa lama waktu yang kita miliki untuk itu?

Blocks in ML Canvas: Evaluation

Bagian terakhir kanvas didedikasikan untuk mengukur seberapa baik sistem bekerja di **Live Monitoring**. Di sinilah kita akan menentukan metode dan metrik untuk mengevaluasi sistem setelah *deployment*, dan untuk mengukur penciptaan nilai.

Data Sources

Di blok ini, kita mengklarifikasi semua sumber data yang tersedia dan memungkinkan untuk digunakan untuk tugas ML. Sebagai contoh, kita dapat mempertimbangkan untuk menggunakan:

- Internal/external databases.
- Data marts, OLAP cubes, data warehouses, OLTP systems.
- Hadoop clusters,
- REST APIs to gather data.
- Static files, spreadsheets.
- Web scraping.
- The output of other (ML) systems.
- Open-source data sets.

Hidden cost dari aplikasi ML:

Seberapa mahal bisa mendapatkan penyimpanan data? Haruskah kita membeli data eksternal?

Alat dan proses penilaian data apa yang tersedia untuk membuat data dapat diakses dari sistem lain?

Prediction Task

Setelah mengklarifikasi data apa yang tersedia, kita melakukan brainstorming jenis ML apa yang harus digunakan.

- *Supervised or unsupervised learning?*
- *Is this anomaly detection?*
- *Is the problem about which option should be taken? (recommendation)*
- *Do we need to predict a continuous value? (regression)*
- *Which category need to be predicted? (classification)*
- *Do we need to group our data? (clustering)*
- *If supervised, what type of ML task should be taken: classification, regression, or ranking?*
- *If classification, will it be binary- or multiclass classification task?*
- *What is the input for a prediction task? e.g. E-mail text.*
- *What is the output of the prediction task? e.g. “spam” and “regular”*
- *What is the degree of complexity our ML Model could assume? e.g. is our model a combination of other ML models? Do we employ ensemble learning? How many hidden layers included in the deep learning model?*
- *What are the complexity costs, such as training and inference time, for the above models?*

Features

- Karena setiap algoritma ML membutuhkan input data dalam bentuk fitur, kita harus mengklarifikasi bagaimana data input harus direpresentasikan.
- Bagaimana kita mengekstrak fitur dari sumber mentah?
- Pertimbangkan untuk menyertakan pakar domain guna menentukan aspek data apa yang paling penting untuk tugas ML tertentu.

Offline Evaluation

- Sebelum penerapan pelatihan model ML apa pun, kami perlu menentukan dan menyiapkan metode dan metrik untuk mengevaluasi sistem sebelum penerapan.
- Metrik evaluasi teknis apa yang harus digunakan? Presisi, F-1 score, Akurasi, dll.
- Apa arti kesalahan prediksi model, seperti positif palsu dan negatif palsu?
- Apa data pengujian kami?
- Berapa banyak data pengujian yang kami perlukan untuk yakin bahwa model ML berperforma baik?

Decisions

- Bagaimana prediksi digunakan untuk membuat keputusan?
- Bagaimana *end-user* atau sistem berinteraksi dengan prediksi model?

  Misalnya Apa yang terjadi jika pengguna mendapatkan daftar rekomendasi produk? Apa jadinya jika email yang masuk tergolong “spam”?
- Apakah ada biaya tersembunyi dalam pengambilan keputusan, misal *human in the loop* ?

Informasi tersebut diperlukan untuk kemudian memutuskan cara menerapkan model ML.

Making Predictions

Blok ini berisi informasi tentang kapan kita membuat prediksi pada input baru.

- Kapan prediksi harus tersedia?
  - Prediksi baru dibuat setiap kali pengguna membuka aplikasi, seperti rekomendasi.
  - Prediksi baru dibuat berdasarkan permintaan.
  - Prediksi baru dibuat sesuai jadwal.
- Apakah prediksi dibuat dengan cepat untuk setiap titik data atau untuk kumpulan data masukan?
- Seberapa kompleks secara komputasi inferensi model dalam aplikasi?
- Apakah ada *human in the loop* untuk mendukung dalam membuat prediksi?

Data Collection

Terkait dengan **Making Predictions**, blok **Data Collection** mengumpulkan informasi tentang data baru yang harus dikumpulkan untuk melatih kembali model ML.

- Bagaimana kami memberi label pada data baru?
- Seberapa mahal untuk mengumpulkan data baru?
- Seberapa mahal untuk memproses media kaya seperti gambar, suara, atau video?
- Apakah ada *human in the loop* untuk pembersihan manual dan pelabelan data yang masuk?

Building Models

Blok ini menjawab pertanyaan terkait pembaruan model ML, karena tugas ML yang berbeda memerlukan frekuensi pelatihan ulang model yang berbeda.

- Seberapa sering model harus dilatih ulang?
  - misalnya setiap jam, mingguan, atau dengan setiap titik data baru.
- Berapa biaya tersembunyi untuk pelatihan ulang model?
  - misalnya apakah kami menggunakan sumber daya cloud untuk melakukan tugas seperti itu?
  - apa kebijakan harga vendor cloud?
  - bagaimana seharusnya kita melakukan estimasi biaya perangkat keras?
  - common *Cloud Pricing Calculators* are Google Cloud Calculator, Amazon ML Pricing, Microsoft Azure Calculator
- Berapa lama waktu yang diperlukan untuk melatih ulang model?
- Bagaimana kita menangani masalah penskalaan operasi cloud karena bisa jadi lebih kompleks dan mahal?
- Apakah kita merencanakan perubahan dalam tumpukan teknologi?
  - misalnya bagaimana kita bisa menghadapi evolusi tumpukan teknologi karena alat baru dan alur kerja pengembangan muncul di AI modern?

Live Evaluation and Monitoring

Setelah penerapan (deployment), model ML harus dievaluasi dan di sini kita perlu menentukan model dan metrik bisnis, yang harus berkorelasi. Secara umum, metrik harus mengikuti metodologi S.M.A.R.T (*Specific, Measurable, Achievable, Relevant,* and *Time-bound*.).

- Bagaimana kita melacak kinerja sistem?
  - misalnya Pengujian A/B
- Bagaimana kita mengevaluasi penciptaan nilai?
  - misalnya pengguna menghabiskan lebih sedikit waktu di kotak masuk.

Hasil dalam tahap ini adalah Machine Learning Canvas yang sudah selesai.

IMPLEMENTASI

Penawaran Real Estat

Pengguna akhir dalam contoh ini: investor properti

Proposisi nilai: lakukan investasi yang lebih baik dengan melihat penawaran terbaik di antara semua properti yang saat ini ada di pasar

Kotak masuk Prioritas

Pengguna akhir: pengguna klien email

Proposisi nilai: membalas pesan penting lebih cepat dan menghabiskan lebih sedikit waktu untuk email

IMPLEMENTASI (2)

Deteksi Ulasan Palsu
Pengguna akhir: platform pemesanan hotel
Proposisi nilai: tingkatkan kepuasan hotel dan pengalaman pengguna platform dengan peringkat yang lebih akurat

Retensi pelanggan
Pengguna akhir: Tim Manajemen Hubungan Pelanggan
Proposisi nilai: mengurangi tingkat churn di antara pelanggan bernilai tinggi dan meningkatkan tingkat keberhasilan upaya retensi.

Referensi

https://medium.com/louis-dorard/from-data-to-ai-with-the-machine-learning-canvas-part-i-d171b867b047

https://www.ownml.co/machine-learning-canvas

https://ml-ops.org/content/phase-zero

Terima kasih